

Halluzinationen

Wenn die KI überzeugend irrt – erkennen, prüfen, vermeiden

Agenda

Was Sie erwarten können

1 Was ist eine Halluzination?

2 Warum halluzinieren LLMs?

3 Halluzinationen erkennen

4 Faktencheck: richtig prüfen

5 Halluzinationen reduzieren

6 Drei Übungen



Was ist eine Halluzination?

Eine Antwort, die überzeugend und flüssig klingt – aber faktisch falsch oder frei erfunden ist.



Erfundene Quellen

Studien, Bücher oder Links, die es gar nicht gibt



Falsche Zahlen

Daten, Statistiken und Preise einfach geraten



Erfundene Zitate

Aussagen, die so nie gefallen sind



Nicht-Existentes

Personen, Produkte oder Funktionen erfunden



Falsche Auskünfte

Recht, Medizin, Steuern – plausibel, aber falsch



Veraltetes Wissen

Stand nach dem Wissensstichtag fehlt



Ein Beispiel

So sieht eine Halluzination im Alltag aus.

Prompt: "Nenne mir 3 wissenschaftliche Studien zu Thema X – mit Autor, Jahr und Titel."

Antwort der KI

Drei perfekt formatierte Studien – mit Autoren, Jahreszahlen und Titeln. Problem: Zwei davon existieren nicht. Die KI hat das Format einer Quellenangabe gelernt, nicht die Fakten dahinter.

Das Tückische: Bei der falschen Antwort klingt die KI genauso selbstsicher wie bei einer richtigen.



Warum halluzinieren LLMs?

Warum halluzinieren LLMs?

Ein Sprachmodell ist kein Lexikon – es erzeugt Sprache, die wahrscheinlich klingt.



Wort-Vorhersage

Rät das wahrscheinlichste nächste Wort
– es „weiß“ nichts



Kein Faktenspeicher

Wissen steckt unscharf in Mustern, nicht
als Datenbank



Wissensstichtag

Nach dem Trainingsdatum fehlen
aktuelle Infos



Lücken füllen

Statt „weiß ich nicht“ wird plausibel
ergänzt



Fehler im Training

Falsches und Veraltetes aus dem Internet



Gefallen wollen

Das Modell will hilfreich wirken und
antwortet lieber



Wann ist das Risiko besonders hoch?

In diesen Situationen sollten Sie besonders wachsam sein.

 Aktuelle Ereignisse nach dem Wissensstichtag

 Nischen- und Spezialwissen

 Exakte Zahlen, Daten, Namen und Zitate

 Recht, Medizin, Steuern und Finanzen

 „Erfinde / nenne mir Quellen“

 Rechnen und Zählen (z. B. Buchstaben zählen)



Halluzinationen erkennen

Warnsignale

An diesen Anzeichen erkennen Sie eine mögliche Halluzination.

▶ Sehr selbstsichere Antwort – ganz ohne Vorbehalt

▶ Quellen oder Links, die sich nicht öffnen lassen

▶ Verdächtig runde oder extrem präzise Zahlen

▶ Widersprüche innerhalb derselben Antwort

▶ „Laut einer Studie ...“ – ohne nachprüfbaren Nachweis

▶ Details, die zu perfekt zur Frage passen



Faktencheck

Vertrauen ist gut. Prüfen ist Pflicht.



So prüfen Sie eine KI-Antwort

Sechs einfache Wege, Aussagen schnell zu verifizieren.



Quellen öffnen

Genannte Links und Studien wirklich anklicken



Gegenprüfen

Dieselbe Frage an ein zweites KI-Modell stellen



Web-Suche

Aussage zusätzlich klassisch im Netz suchen



Nachhaken

„Bist du sicher? Belege das mit Quelle.“



Original lesen

Primärquelle statt KI-Zusammenfassung prüfen



Fachperson

Bei Recht, Medizin, Geld zur Expertin gehen



Halluzinationen reduzieren

Reduzieren – mit den richtigen Werkzeugen

Geben Sie der KI Zugang zu echten, aktuellen Fakten.



Web-Suche

Browsing aktivieren für aktuelle Infos



Deep Research

Für wichtige, gründliche Recherchen



Eigene Dokumente

Hochladen als Faktenbasis (Grounding)



RAG / NotebookLM

Antworten auf deine Quellen stützen



Besseres Modell

Neueres oder größeres Modell wählen



Thinking-Modus

Reasoning einschalten für mehr Sorgfalt



Reduzieren – mit klugem Prompting

Schon kleine Zusätze im Prompt senken das Risiko deutlich.

💬 „Wenn du es nicht sicher weißt, sag es ehrlich.“

💬 „Antworte nur auf Basis der bereitgestellten Quellen.“

💬 „Nenne für jede Aussage eine Quelle mit Link.“

💬 Eng und konkret fragen statt breit und vage

💬 „Gehe Schritt für Schritt vor.“

💬 „Kennzeichne Annahmen und Unsicherheiten.“



Goldene Regeln

Drei Grundsätze für den sicheren Umgang.



KI ist ein Praktikant

Schnell und hilfreich – aber kein Lexikon



Wichtig? Verifizieren

Je höher der Einsatz, desto mehr prüfen



Keine Quelle = kein Beleg

Behaupten ist nicht beweisen

Faustregel

Nutzen Sie KI für den ersten Entwurf – aber unterschreiben Sie nie etwas, das Sie nicht selbst geprüft haben.



Halluzination provozieren

Bringen Sie die KI gezielt zum Halluzinieren – so lernen Sie ihre Grenzen kennen.

Aufgabe: In ChatGPT, Gemini oder Claude – Web-Suche dabei ausgeschaltet lassen.

„Nenne 3 wissenschaftliche Studien zu [Nischenthema] mit Autor, Jahr, Titel.“

„Fasse das Buch ‚[erfundener Titel]‘ von [erfundener Autor] zusammen.“

„Was geschah gestern bei [aktuelles Ereignis]?“

„Zitiere § ... des [Spezialgesetz] wörtlich.“

„Wie oft kommt der Buchstabe ‚L‘ in ‚LOLLAPALOOZA‘ vor?“

Reflexion: Wie selbstsicher klingt die KI bei den falschen Antworten?



Entlarven & prüfen

 20 Min

Nehmen Sie eine Antwort mit Quellen aus Übung 1 und prüfen Sie jede Angabe.

Aufgabe: Faktencheck durchführen – Schritt für Schritt.

1. Öffnen Sie jeden genannten Link / suchen Sie jede Studie
2. Markieren Sie: echt – ungenau – frei erfunden
3. Fragen Sie die KI: „Bist du sicher? Belege jede Quelle mit Link.“
4. Beobachten Sie: Rudert die KI jetzt zurück?

Reflexion: Wie viele Angaben waren überprüfbar? Was war erfunden?



Reduzieren & vergleichen

Stellen Sie dieselbe Frage erneut – mit den Werkzeugen gegen Halluzinationen.

Aufgabe: Eine Frage aus Übung 1 in drei Varianten testen und vergleichen.

A. Frage ohne Web-Suche (Ergebnis aus Übung 1)

B. Gleiche Frage mit Web-Suche / Deep Research

C. Zusätzlich: „Nur belegte Fakten, mit Quellen-Links.“

Vergleichen Sie Genauigkeit und Quellenlage der drei Antworten

Reflexion: Welche Maßnahme hat am meisten geholfen?



Zusammenfassung

Das Wichtigste auf einen Blick.

Halluzination = überzeugend formuliert, aber falsch oder erfunden

Ursache: KI rät plausible Wörter und hat kein Faktengedächtnis

Erkennen: große Selbstsicherheit + fehlende oder erfundene Quellen

Prüfen: Quellen öffnen, gegenfragen, Original lesen

Reduzieren: Web-Suche, Deep Research, eigene Quellen, ehrliches Prompting

Vertrauen ist gut. Prüfen ist Pflicht.